

LAPORAN TEKNIS KOMPREHENSIF
KEMUDI: SISTEM PEMANTAUAN KANTUK PENGEMUDI
CC26-PSU369

Capstone Project
Coding Camp 2026 powered by DBS Foundation
Learning Path Data Scientist

Disusun oleh:

Artika Sari Dewanti CDCC008D6X1052

Keisya Nazalia Azally CDCC008D6X1397

1. Pendahuluan

Proyek KEMUDI (Sistem Pemantauan Kantuk Pengemudi) merupakan solusi berbasis teknologi *computer vision* yang dikembangkan untuk membantu mendeteksi kondisi kantuk pada pengemudi secara dini. Latar belakang dari proyek ini adalah tingginya angka kecelakaan lalu lintas yang disebabkan oleh *microsleep* atau kondisi pengemudi tertidur sesaat saat berkendara.

Sistem ini memanfaatkan citra mata (open dan closed) yang diproses menggunakan model *deep learning* berbasis Convolutional Neural Network (CNN) untuk mengklasifikasikan kondisi pengemudi. Selain itu, sistem juga dirancang agar dapat berjalan secara *real-time* dengan latency rendah sehingga dapat memberikan peringatan secara langsung kepada pengguna.

Proyek ini tidak hanya berfokus pada pengembangan model, tetapi juga mencakup pipeline data science secara menyeluruh, mulai dari pengumpulan data, preprocessing, eksplorasi data, hingga evaluasi model dan implementasi ke dalam sistem berbasis web.

2. Problem Discovery

Permasalahan utama yang diangkat dalam proyek ini adalah bagaimana mendeteksi kondisi kantuk pengemudi secara akurat dan real-time menggunakan perangkat yang sederhana seperti webcam.

Beberapa tantangan yang diidentifikasi antara lain:

- Variasi kondisi pencahayaan (siang, malam, senja) yang dapat memengaruhi performa model
- Perbedaan karakteristik wajah pengguna (kacamata, masker, sudut wajah)
- Potensi *false positive* yang dapat menyebabkan alarm tidak relevan
- Kebutuhan sistem dengan latency rendah (< 0.5 detik) agar tetap responsif secara real-time

Selain itu, dataset yang digunakan juga harus cukup representatif agar model dapat melakukan generalisasi dengan baik terhadap berbagai kondisi dunia nyata. Oleh karena itu, diperlukan proses augmentasi data dan penggunaan dataset tambahan sebagai pendukung.

Permasalahan ini menjadi krusial karena solusi yang tidak akurat justru dapat mengurangi kepercayaan pengguna terhadap sistem.

3. Solusi yang Dikembangkan

Untuk menjawab permasalahan deteksi kantuk pengemudi, dikembangkan sebuah sistem berbasis *pipeline* yang terdiri dari beberapa tahapan utama sebagai berikut.

a. Pengolahan Data

Pada tahap ini dilakukan pengumpulan dataset citra mata yang terdiri dari dua kelas, yaitu kondisi terbuka (*open*) dan tertutup (*closed*). Data kemudian diproses melalui beberapa tahap:

- Preprocessing:
 - Resize gambar
 - Normalisasi pixel
 - Konversi warna
- Augmentasi data:
 - Rotasi
 - Flip
 - Penyesuaian brightness

b. Pengembangan Model

Model yang digunakan adalah Convolutional Neural Network (CNN) untuk mengklasifikasikan kondisi mata. Proses training dilakukan menggunakan TensorFlow/Keras, dengan evaluasi menggunakan beberapa metrik berikut:

- Accuracy
- Precision
- Recall

- F1-score

Target performa model yang diharapkan adalah minimal $\geq 85\%$.

c. Feature Engineering

Untuk meningkatkan kualitas deteksi, sistem tidak hanya mengandalkan prediksi satu frame, tetapi juga mempertimbangkan pola temporal:

- Menghitung durasi mata tertutup
- Menghitung frekuensi mata tertutup
- Menggunakan beberapa frame berurutan untuk meningkatkan stabilitas deteksi

d. Penentuan Threshold

Penentuan threshold dilakukan untuk membedakan kondisi normal dan kantuk, dengan nilai optimal pada rentang:

- 0.25 – 0.30

e. Implementasi Sistem

Sistem diimplementasikan dalam bentuk aplikasi real-time dengan arsitektur sebagai berikut:

- Backend: FastAPI
- Frontend: Next.js
- Integrasi: WebSocket (real-time)

Sistem juga dilengkapi dengan mekanisme alert bertingkat:

- Hijau (normal)
- Kuning (waspada)
- Merah (kantuk) + alarm suara

Dengan pendekatan ini, sistem diharapkan mampu memberikan deteksi yang akurat sekaligus responsif dalam kondisi nyata.

4. Business Questions

Berikut adalah pertanyaan bisnis utama yang ingin dijawab melalui proyek ini:

- 1) Apakah kondisi mata terbuka dan tertutup dapat digunakan sebagai indikator awal dalam mendeteksi kantuk pengemudi?
- 2) Bagaimana karakteristik dan keseimbangan dataset (open vs closed) memengaruhi performa model?
- 3) Apakah feature engineering melalui preprocessing citra mampu menghasilkan input gambar yang seragam dan siap digunakan untuk model klasifikasi?
- 4) Seberapa baik performa model dalam mengklasifikasikan kondisi mata berdasarkan metrik evaluasi seperti accuracy, precision, recall, F1-score, dan confusion matrix?
- 5) Threshold prediksi berapa yang paling optimal untuk membedakan kondisi mata Open dan Closed berdasarkan validation set?
- 6) Apakah model memiliki latency yang cukup rendah untuk mendukung sistem deteksi kantuk secara real-time?

Pertanyaan-pertanyaan ini menjadi dasar dalam proses analisis data, pengembangan model, serta evaluasi sistem secara keseluruhan.

5. Data Wrangling

Data wrangling dilakukan untuk memastikan dataset yang digunakan sudah layak, rapi, dan siap diproses pada tahap analisis maupun evaluasi model. Pada proyek ini, data tidak langsung digunakan begitu saja, tetapi melalui proses pengecekan terlebih dahulu. Pengecekan dilakukan terhadap struktur folder, jumlah data setiap kelas, kelengkapan metadata, kemungkinan duplikasi, gambar yang gagal baca, serta variasi ukuran gambar.

5.1 Gathering Data

Dataset yang digunakan pada proyek ini adalah MRL Dataset yang diunduh dari Kaggle. Dataset ini berisi citra mata yang terbagi ke dalam dua kelas, yaitu Closed_Eyes untuk kondisi mata tertutup dan Open_Eyes untuk mata terbuka. Label mapping yang digunakan yaitu 0 untuk Closed dan 1 untuk Open.

Setelah dataset diunduh, folder data diarahkan ke folder train yang memuat dua subfolder kelas tersebut. Struktur folder yang sudah terpisah berdasarkan kelas membantu proses pembacaan data, pelabelan, dan penyusunan metadata. Pemilihan dataset ini didasarkan dengan kebutuhan proyek KEMUDI, yaitu membedakan kondisi mata terbuka dan tertutup sebagai indikator awal dalam sistem deteksi kantuk pengemudi.

5. 2 Assessing Data

Tahap assessing data dilakukan untuk mengecek kondisi awal dataset sebelum masuk ke tahap cleaning dan feature engineering atau preprocessing. Pengecekan dilakukan dengan membuat dataframe metadata yang berisi `image_path`, `label`, dan `class`. Dataframe ini digunakan untuk memudahkan proses pemeriksaan data gambar secara lebih terstruktur.

Beberapa aspek yang dicek yaitu jumlah data per kelas, missing value, duplikasi, gambar corrupt atau gagal baca, serta variasi ukuran gambar. Berdasarkan hasil pengecekan, dataset memiliki distribusi kelas yang seimbang antara Closed dan Open. Selain itu, tidak ditemukan missing value, duplikasi `image_path`, maupun gambar corrupt. Namun, ukuran gambar masih bervariasi sehingga proses preprocessing tetap diperlukan agar seluruh gambar memiliki ukuran input yang seragam.

Tabel 1. Ringkasan Assessing Data

Aspek yang Dicek	Hasil
Struktur folder kelas	Tersedia: Closed_Eyes dan Open_Eyes
Kolom metadata	<code>image_path</code> , <code>label</code> , <code>class</code>
Distribusi kelas	Seimbang antara Closed dan Open
Missing value	Tidak ditemukan
Duplikasi <code>image_path</code>	Tidak ditemukan
Corrupt image	Tidak ditemukan

Variasi ukuran gambar	Ditemukan variasi ukuran
-----------------------	--------------------------

5. 3 Cleaning Data

Tahap cleaning dilakukan untuk memastikan data yang digunakan bebas dari gambar corrupt dan duplikasi. Proses cleaning dilakukan dengan menghapus gambar yang gagal dibaca apabila ditemukan, serta menghapus data dengan image_path yang duplikat. Berdasarkan hasil assessing data, tidak ditemukan gambar yang gagal dibaca maupun data duplikat. Oleh karena itu, tidak ada data yang perlu dihapus dan jumlah data setelah cleaning tetap sama dengan jumlah data awal.

Namun, tahap cleaning tetap dicantumkan karena dataset tidak langsung digunakan begitu saja. Dataset tetap melalui proses pengecekan kualitas data terlebih dahulu untuk memastikan bahwa seluruh gambar dapat dibaca, tidak terdapat duplikasi, dan layak dilanjutkan ke tahap preprocessing. Hal ini menunjukkan bahwa dataset telah melalui proses pembersihan yang sistematis dan berada dalam kondisi bersih serta siap untuk tahap preprocessing dan pemodelan.

Tabel 2. Ringkasan Cleaning Data

Tahap Cleaning	Hasil
Penghapusan corrupt image	Tidak ada data yang dihapus
Penghapusan duplikasi image_path	Tidak ada data yang dihapus
Jumlah data setelah cleaning	Tetap sama dengan jumlah data awal

6. Feature Engineering

Pada proyek ini, feature engineering dilakukan dalam bentuk preprocessing citra. Hal ini karena data yang digunakan berupa gambar mata, bukan data tabular yang memiliki kolom-kolom numerik seperti umur, durasi, atau nilai tertentu. Pada data gambar, informasi utama

berada pada pola visual, seperti bentuk mata, area kelopak, dan perbedaan tampilan antara mata terbuka dan tertutup.

Oleh karena itu, proses feature engineering difokuskan untuk mengubah gambar mentah menjadi input yang seragam dan sesuai dengan kebutuhan model CNN. Tahapan yang dilakukan meliputi resize gambar menjadi 96×96 piksel, konversi gambar ke grayscale, normalisasi nilai pixel dari rentang 0-255 menjadi 0-1, serta penyesuaian dimensi menjadi $96 \times 96 \times 1$.

Tahap resize dilakukan karena gambar pada dataset memiliki ukuran yang bervariasi. Jika gambar dengan ukuran berbeda langsung dimasukkan ke model, maka model tidak dapat memproses input secara konsisten. Dengan mengubah seluruh gambar menjadi ukuran 96×96 piksel, setiap data memiliki dimensi yang sama.

Konversi grayscale dilakukan untuk menyederhanakan informasi warna pada gambar. Dalam kasus deteksi kondisi mata, informasi yang paling penting bukan warna, melainkan pola bentuk mata terbuka atau tertutup. Grayscale juga membuat input menjadi lebih ringan karena hanya memiliki satu channel sehingga bentuk akhir gambar menjadi $96 \times 96 \times 1$.

Normalisasi pixel dilakukan dengan mengubah nilai pixel dari rentang 0-255 menjadi 0-1. Proses ini membantu membuat nilai input lebih stabil dan sesuai format yang dibutuhkan model deep learning. Setelah seluruh tahapan dilakukan, data gambar sudah siap digunakan untuk proses evaluasi model.

Tabel 3. Ringkasan Feature Engineering

Tahap	Keterangan
Resize	Seluruh gambar diubah menjadi ukuran 96×96 piksel
Grayscale	Gambar dikonversi menjadi satu channel warna
Normalisasi	Nilai pixel diubah dari rentang 0-255 menjadi 0-1

Penyesuaian dimensi	Input gambar dibentuk menjadi $96 \times 96 \times 1$
Tujuan	Menyeragamkan format gambar agar sesuai dengan input model CNN

Dengan demikian, feature engineering pada proyek ini dilakukan dengan pendekatan preprocessing citra karena model CNN dapat mempelajari pola visual langsung dari gambar yang sudah diproses.

7. Split Data

Setelah gambar selesai diproses pada tahap feature engineering/preprocessing citra, dataset kemudian dibagi menjadi tiga bagian, yaitu train set, validation set, dan test set. Pembagian data mengikuti pipeline yang digunakan oleh learning path AI, yaitu 70% train, 15% validation, dan 15% test. Hal ini dilakukan agar proses evaluasi dari sisi Data Scientist tetap konsisten dengan data yang digunakan dalam pengembangan model.

Pembagian data dilakukan menggunakan metode stratified split agar proporsi kelas Closed dan Open tetap seimbang pada setiap subset. Dalam pipeline ini, train set digunakan untuk proses pelatihan model oleh AI, validation set digunakan untuk threshold analysis dan A/B testing, sedangkan test set digunakan untuk evaluasi akhir model.

Tabel 4. Pembagian Dataset

Subset Data	Proporsi	Fungsi
Train set	70%	Digunakan dalam pipeline AI untuk proses pelatihan model
Validation set	15%	Digunakan untuk threshold analysis dan A/B testing
Test set	15%	Digunakan untuk evaluasi akhir model

Berdasarkan hasil split, distribusi kelas pada setiap subset tetap seimbang antara Closed dan Open. Dengan demikian, data validation dan test yang digunakan dalam evaluasi tetap merepresentasikan kedua kelas secara proporsional.

Tabel 5. Distribusi Kelas pada Setiap Subset

Class	Train	Validation	Test
Closed	1.400	300	300
Open	1.400	300	300

Dari tabel tersebut, terlihat bahwa data pada train, validation, dan test set tetap seimbang antara kelas Closed dan Open. Dengan pembagian seperti ini, model dapat dievaluasi secara lebih adil karena kedua kelas sama-sama terwakili.

8. Data Dictionary

Data dictionary disusun untuk menjelaskan struktur data yang digunakan dalam notebook Data Scientist. Bagian ini membantu pembaca memahami arti setiap kolom dan objek data yang muncul dalam proses analisis, mulai dari data gambar mentah, label kelas, hasil preprocessing, hingga data yang sudah dibagi menjadi train, validation, dan test set,

Pada proyek ini, label data mengikuti pipeline AI, yaitu 0 = Closed dan 1 = Open. Label ini digunakan secara konsisten pada proses pembacaan dataset, preprocessing citra, split data, serta evaluasi model.

Tabel 6. Data Dictionary

Objek Data	Type Data	Deskripsi
string	image_path	Lokasi file gambar pada direktori dataset.
integer	label	Label numerik gambar. 0 = Closed, 1 = Open.

string	class	Nama kelas gambar, yaitu Closed atau Open.
numpy array	images	Kumpulan gambar hasil feature engineering/preprocessing dengan ukuran 96x96, grayscale, dan nilai pixel 0-1.
numpy array	labels	Kumpulan label numerik dari seluruh gambar.
numpy array	x_train	Subset gambar untuk data training sesuai split pipeline AI.
numpy array	x_val	Subset gambar untuk data validation yang digunakan dalam threshold analysis dan A/B testing.
numpy array	x_test	Subset gambar untuk data testing yang digunakan dalam evaluasi akhir model.
numpy array	y_train	Label untuk data training.
numpy array	y_val	Label untuk data validation.
numpy array	y_test	Label untuk data testing.

Dengan struktur data seperti ini, proses analisis, threshold analysis, A/B testing, hingga evaluasi model dapat dilakukan dengan lebih terstruktur dan mudah ditelusuri pada setiap tahap pipeline.

9. Exploratory Data Analysis

Exploratory Data Analysis (EDA) dilakukan untuk memahami karakteristik dataset sebelum data digunakan pada proses evaluasi model. Pada proyek ini, EDA difokuskan untuk melihat distribusi kelas, variasi gambar, ukuran input, serta hasil pembagian dataset train, validation, dan test set.

Exploratory Data Analysis (EDA) juga dilakukan dengan menyertakan penjelasan deskriptif pada setiap hasil analisis yang ditampilkan. Setiap visualisasi, seperti distribusi kelas, variasi ukuran gambar, dan pembagian dataset, dilengkapi dengan interpretasi dalam bentuk teks untuk memastikan pemahaman yang komprehensif terhadap karakteristik data.

Setiap kesimpulan yang diambil dalam proses analisis didukung oleh visualisasi data yang relevan, seperti bar chart dan histogram. Pendekatan ini memastikan bahwa seluruh insight yang dihasilkan memiliki dasar yang kuat dan dapat dipertanggungjawabkan secara analitis.

Melalui tahap ini, beberapa insight awal dapat diperoleh, seperti keseimbangan jumlah data antar kelas, kebutuhan preprocessing citra, serta kesiapan data sebelum digunakan pada pipeline model CNN.

9.1 Distribusi Kelas Dataset

Analisis pertama dilakukan untuk melihat distribusi jumlah data pada masing-masing kelas, yaitu Closed dan Open. Pengecekan ini penting karena distribusi data yang terlalu tidak seimbang dapat menyebabkan model lebih condong mempelajari salah satu kelas dibanding kelas lainnya.


Hasil perhitungan jumlah data pada masing-masing kelas ditunjukkan pada tabel berikut.

Tabel 7. Distribusi Jumlah Data per Kelas

Class	Count
Closed	2000
Open	2000

Setelah itu, distribusi kelas divisualisasikan menggunakan bar chart untuk mempermudah proses observasi terhadap keseimbangan dataset.

Gambar 1. Distribusi Kelas Dataset




Berdasarkan hasil visualisasi, dataset memiliki distribusi yang seimbang antara kelas Closed dan Open, dengan masing-masing kelas berjumlah 2.000 gambar. Kondisi ini membantu mengurangi potensi bias model terhadap salah satu kelas selama proses evaluasi. Distribusi data yang seimbang juga membuat hasil evaluasi model menjadi lebih representatif, terutama pada metrik seperti precision, recall, dan F1-score.

9.2 Contoh Gambar Dataset Open dan Closed

Setelah melihat distribusi jumlah data, analisis dilanjutkan dengan menampilkan beberapa contoh gambar dari masing-masing kelas, yaitu Closed dan Open. Tahap ini dilakukan untuk memahami karakteristik visual dataset secara langsung sebelum data masuk ke tahap preprocessing dan evaluasi model.

Gambar 2. Contoh Gambar Kelas Open dan Closed



Berdasarkan contoh gambar tersebut, terlihat bahwa kelas Closed berisi gambar mata dalam kondisi tertutup, sedangkan kelas Open menunjukkan mata yang masih terbuka dengan area pupil yang masih terlihat. Perbedaan visual antara kedua kelas ini cukup jelas sehingga dapat membantu model dalam membedakan kondisi mata terbuka dan tertutup.

Dari beberapa contoh gambar juga terlihat bahwa dataset tidak hanya berisi satu jenis tampilan mata. Terdapat variasi bentuk mata, sudut pengambilan gambar, pencahayaan, hingga beberapa gambar dengan penggunaan kacamata. Variasi ini membuat dataset menjadi lebih beragam dan lebih mendekati kondisi penggunaan di dunia nyata.

9.3 Variasi Ukuran Gambar Sebelum Preprocessing

Selain melihat distribusi kelas dan contoh gambar dataset, dilakukan juga pengecekan terhadap ukuran gambar sebelum preprocessing. Tahap ini penting karena gambar pada dataset berasal dari berbagai kondisi pengambilan sehingga ukuran input yang dimiliki belum tentu seragam.

Hasil pengecekan menunjukkan bahwa dataset memiliki beberapa variasi ukuran gambar. Contoh ukuran gambar yang ditemukan ditunjukkan pada tabel berikut.


Tabel 8. Contoh Ukuran Gambar Sebelum Preprocessing

Height	Width	Channel
92	92	3

93	93	3
95	95	3
97	97	3
99	99	3

Selain ditampilkan dalam bentuk tabel, distribusi ukuran gambar juga divisualisasikan menggunakan histogram untuk melihat persebaran ukuran gambar pada dataset.

Gambar 3. Distribusi Gambar Sebelum Preprocessing



Berdasarkan hasil visualisasi, terlihat bahwa ukuran gambar pada dataset masih cukup bervariasi meskipun sebagian besar berada pada rentang ukuran yang hampir serupa. Variasi ukuran ini menyebabkan data belum dapat langsung digunakan sebagai input model CNN karena model membutuhkan dimensi input yang konsisten.

Selain itu, seluruh gambar masih memiliki tiga channel warna (RGB). Padahal, pada proyek ini informasi yang paling dibutuhkan adalah pola kondisi mata terbuka dan tertutup, bukan informasi warna gambar. Oleh karena itu, preprocessing dilakukan dengan

mengubah seluruh gambar menjadi grayscale sekaligus menyeragamkan ukuran input menjadi 96×96 piksel.

Dengan preprocessing tersebut, seluruh gambar dapat memiliki format input yang lebih konsisten sehingga lebih sesuai untuk digunakan pada proses evaluasi model.

9.4 Distribusi Split Dataset

Setelah seluruh gambar selesai diproses pada tahap preprocessing, dataset kemudian dibagi menjadi train set, validation set, dan test set. Pembagian data dilakukan untuk memastikan proses evaluasi model dapat berjalan secara terpisah dan lebih terstruktur.

Pada proyek ini, pembagian data mengikuti pipeline AI, yaitu 70% untuk train set, 15% untuk validation set, dan 15% untuk test set. Selain itu, proses split dilakukan menggunakan stratified split agar distribusi kelas Closed dan Open tetap seimbang pada setiap subset.


Hasil pembagian dataset ditunjukkan pada tabel berikut.

Tabel 9. Pembagian Dataset ke dalam Data Train, Validation, dan Test

Class	Train	Validation	Test
Closed	1400	300	300
Open	1400	300	300

Distribusi data tersebut kemudian divisualisasikan menggunakan grouped bar chart untuk mempermudah observasi terhadap proporsi masing-masing kelas pada setiap subset data.

Gambar 4. Distribusi Kelas pada Train, Validation, dan Test Set



Berdasarkan hasil visualisasi, distribusi kelas pada train, validation, dan test set tetap seimbang antara Closed dan Open. Dengan pembagian seperti ini, setiap subset tetap memiliki representasi data dari kedua kelas sehingga proses evaluasi model dapat dilakukan secara lebih konsisten.

Train set digunakan dalam proses pengembangan model pada pipeline AI, sedangkan validation set digunakan untuk threshold analysis dan A/B testing. Sementara itu, test set digunakan untuk evaluasi akhir model agar performa model dapat diuji pada data yang belum pernah digunakan sebelumnya.

9.5 Ringkasan Hasil Exploratory Data Analysis

Berdasarkan seluruh proses exploratory data analysis yang telah dilakukan, diperoleh beberapa insight utama terkait kondisi dataset sebelum digunakan pada proses evaluasi model. Ringkasan hasil EDA ditunjukkan pada tabel berikut.

Tabel 10. Ringkasan Hasil Exploratory Data Analysis

Aspek Analisis	Hasil Insight
Distribusi kelas	Dataset memiliki distribusi yang seimbang antara kelas Closed dan Open
Kualitas data	Tidak ditemukan missing value, duplikasi image path, maupun gambar corrupt
Variasi gambar	Dataset memiliki variasi bentuk mata, sudut pengambilan gambar, dan pencahayaan
Ukuran gambar	Ukuran gambar masih bervariasi sehingga perlu preprocessing
Preprocessing	Seluruh gambar diubah menjadi grayscale dan resize 96×96
Split dataset	Distribusi kelas pada train, validation, dan test set tetap seimbang

Secara keseluruhan, hasil EDA menunjukkan bahwa dataset sudah siap digunakan pada proses evaluasi model. Variasi ukuran dan tampilan gambar yang ditemukan pada dataset juga menjadi alasan dilakukannya preprocessing, seperti resize, grayscale, dan normalisasi, agar seluruh input memiliki format yang lebih seragam saat digunakan pada model CNN.

9.6 Validasi Kesiapan Dataset

Dataset akhir telah melalui seluruh tahapan preprocessing sehingga memiliki format yang konsisten, meliputi ukuran gambar yang seragam, representasi grayscale, serta normalisasi nilai pixel. Selain itu, dataset telah dibagi menjadi train, validation, dan test set menggunakan stratified split, sehingga siap digunakan dalam proses pelatihan dan evaluasi model tanpa memerlukan pemrosesan tambahan.

Tidak ditemukan indikasi data leakage dalam proses pengolahan data. Pemisahan antara fitur dan label dilakukan secara jelas sebelum tahap pelatihan model. Selain itu, pembagian

dataset ke dalam train, validation, dan test set dilakukan di awal pipeline sehingga tidak terjadi kebocoran informasi antar subset data selama proses evaluasi.

Secara keseluruhan, seluruh tahapan pengolahan data pada proyek ini telah mengikuti prinsip-prinsip Data Science yang baik dan memenuhi standar evaluasi yang ditetapkan.

10. Model Evaluation

Model evaluation dilakukan menggunakan test set untuk melihat kemampuan model dalam membedakan kondisi mata Open dan Closed. Evaluasi dilakukan menggunakan beberapa metrik, yaitu accuracy, precision, recall, F1-score, dan confusion matrix.

Metrik tersebut dipilih karena tidak hanya menunjukkan tingkat ketepatan model secara umum, tetapi juga membantu melihat konsistensi model dalam mengenali masing-masing kelas.

Tabel 11. Hasil Evaluasi Model


Metric	Value
Accuracy	1.0000
Precision	1.0000
Recall	1.0000
F1-score	1.0000

Berdasarkan hasil evaluasi, model memperoleh nilai accuracy, precision, recall, dan F1-score sebesar 1.0000 pada test set. Hasil ini menunjukkan bahwa model mampu membedakan kondisi mata terbuka dan tertutup dengan sangat baik pada data pengujian yang digunakan.

Nilai precision yang tinggi menunjukkan bahwa model tidak menghasilkan false positive pada test set, sedangkan recall yang tinggi menunjukkan bahwa seluruh data Closed berhasil dikenali tanpa ada data yang terlewat. Selain itu, nilai F1-score yang tinggi juga menunjukkan bahwa keseimbangan antara precision dan recall tetap terjaga.

Untuk melihat hasil prediksi secara lebih detail, evaluasi juga dilakukan menggunakan confusion matrix.

Gambar 5. Confusion Matrix Hasil Evaluasi Model



Berdasarkan confusion matrix, seluruh data pada test set berhasil diklasifikasikan dengan benar. Sebanyak 300 data Open diprediksi sebagai Open dan 300 data Closed diprediksi sebagai Closed. Pada hasil pengujian ini, tidak ditemukan false positive maupun false negative.

Meskipun hasil evaluasi menunjukkan performa yang sangat baik, pengujian ini masih dilakukan menggunakan dataset statis. Oleh karena itu, performa model pada kondisi nyata

tetap perlu diuji lebih lanjut, terutama pada variasi pencahayaan, sudut wajah, dan kondisi penggunaan webcam secara langsung.


11. A/B Testing

A/B testing dilakukan untuk membandingkan dua strategi penentuan threshold dalam proses klasifikasi kondisi mata, yaitu penggunaan threshold default sebesar 0.5 (Strategi A) dan threshold hasil analisis dari validation set sebesar 0.007 (Strategi B). Pengujian ini dilakukan untuk melihat apakah perubahan nilai threshold benar-benar memberikan pengaruh terhadap performa model.

Tabel 12. Perbandingan Performa Model pada A/B Testing

Experiment	Threshold	Accuracy	Precision	Recall	F1-Score
A - Default Threshold	0.5	1.00	1.00	1.00	1.00
B - Best Threshold	0.007	1.00	1.00	1.00	1.00

Gambar 6. Visualisasi Perbandingan Performa Model pada A/B Testing



Hasil pengujian menunjukkan bahwa kedua strategi menghasilkan performa yang identik pada seluruh metrik evaluasi, yaitu accuracy, precision, recall, dan F1-score. Hasil ini menunjukkan bahwa model sudah mampu membedakan kondisi mata terbuka dan tertutup

dengan sangat konsisten sehingga perubahan threshold tidak banyak memengaruhi hasil prediksi.

Berdasarkan hasil tersebut, dipilih threshold default sebesar 0.5 sebagai threshold final yang digunakan dalam sistem. Pemilihan ini didasarkan pada pertimbangan stabilitas dan kemudahan interpretasi karena threshold default lebih umum digunakan serta lebih mudah dipahami dalam implementasi sistem. Dari hasil tersebut, penggunaan threshold default sebesar 0.5 sudah cukup optimal untuk digunakan pada sistem deteksi kantuk yang dikembangkan.

12. Latency Test

Latency test dilakukan untuk mengukur kecepatan inferensi model dalam memproses data gambar sebagai indikator kesiapan sistem dalam mendukung implementasi real-time. Pengujian dilakukan menggunakan 100 sampel gambar dalam kondisi terisolasi (tanpa beban sistem lain) untuk melihat performa model tanpa dipengaruhi komponen sistem lainnya.

Tabel 13. Hasil Pengujian Latency Model

Metric	Value
Sample Size	100
Total Inference Time (s)	0.6837
Average Latency per Image (s)	0.0068
Estimated FPS	146.2587

Berdasarkan hasil pengujian, diperoleh rata-rata waktu inferensi per gambar sebesar sekitar 0.0068 detik, dengan estimasi kecepatan mencapai sekitar 146 frame per detik (FPS). Hasil ini menunjukkan bahwa model memiliki kemampuan pemrosesan yang sangat cepat dan efisien.

Hasil ini menunjukkan bahwa model sudah cukup cepat untuk digunakan pada sistem real-time seperti deteksi kantuk berbasis webcam. Namun demikian, perlu diperhatikan bahwa pengujian ini dilakukan dalam kondisi terisolasi sehingga belum sepenuhnya merepresentasikan performa sistem saat diintegrasikan dengan komponen lain seperti backend, frontend, dan streaming kamera. Oleh karena itu, pengujian lanjutan pada lingkungan produksi tetap diperlukan untuk memastikan performa sistem secara keseluruhan.

13. Streamlit Dashboard

Streamlit dashboard dikembangkan sebagai media visualisasi untuk menampilkan hasil analisis data serta evaluasi model secara interaktif. Dashboard ini dirancang untuk membantu pengguna maupun reviewer memahami alur kerja Data Science pada proyek KEMUDI secara lebih ringkas dan visual.

Dashboard menampilkan beberapa bagian utama, mulai dari project overview, data insight, feature engineering, model evaluation, threshold analysis, A/B testing, hingga latency test. Seluruh hasil analisis ditampilkan menggunakan visualisasi interaktif, tabel ringkasan, serta insight singkat agar informasi lebih mudah dipahami.

Selain digunakan sebagai media visualisasi, dashboard ini juga berfungsi sebagai dokumentasi pipeline Data Science yang telah dilakukan, mulai dari proses pengolahan dataset hingga evaluasi performa model.

Akses dashboard dapat dilakukan melalui link berikut:

Dashboard Streamlit KEMUDI

<https://cc26-psu369-kemudi-data-scientist-ttoqnxqw5cvd2tcqkspafq.streamlit.app/>

14. Kesimpulan

Berdasarkan seluruh rangkaian proses analisis data, pengembangan model, serta evaluasi sistem yang telah dilakukan pada proyek KEMUDI (Sistem Pemantauan Kantuk Pengemudi), dapat disimpulkan bahwa pendekatan berbasis *computer vision* dengan

memanfaatkan klasifikasi kondisi mata (open dan closed) mampu menjadi indikator awal yang efektif dalam mendeteksi kantuk pengemudi.

Hasil pengolahan data menunjukkan bahwa dataset yang digunakan memiliki kualitas yang baik, dengan distribusi kelas yang seimbang serta tidak ditemukan missing value, duplikasi, maupun gambar corrupt. Proses *feature engineering* melalui preprocessing citra, seperti resize, konversi grayscale, dan normalisasi pixel, berhasil menghasilkan input yang seragam dan sesuai untuk model CNN.

Model yang dikembangkan mampu mencapai performa yang sangat baik pada data uji, dengan nilai accuracy, precision, recall, dan F1-score yang tinggi. Hal ini menunjukkan bahwa model memiliki kemampuan yang sangat baik dalam membedakan kondisi mata terbuka dan tertutup.

Selain itu, hasil *threshold analysis* dan *A/B testing* menunjukkan bahwa penggunaan threshold default tetap memberikan performa yang optimal dan stabil. Dari sisi performa sistem, hasil *latency test* menunjukkan bahwa sistem memiliki waktu respons yang cukup rendah sehingga berpotensi untuk digunakan dalam skenario real-time.

Namun demikian, perlu diperhatikan bahwa hasil evaluasi ini masih dilakukan pada kondisi terkontrol menggunakan dataset statis, sehingga performa sistem di lingkungan nyata masih perlu diuji lebih lanjut.

15. Rekomendasi

Berdasarkan hasil analisis dan keterbatasan yang telah diidentifikasi, terdapat beberapa rekomendasi pengembangan untuk meningkatkan kualitas dan kesiapan sistem KEMUDI ke depannya.

Pertama, diperlukan pengujian model secara langsung pada kondisi nyata menggunakan webcam atau perangkat kamera lainnya. Hal ini penting untuk memastikan bahwa model

tetap memiliki performa yang baik pada berbagai kondisi lingkungan, seperti variasi pencahayaan, sudut wajah, serta pergerakan pengguna.

Kedua, disarankan untuk memperkaya dataset dengan menambahkan variasi data yang lebih beragam, seperti pengguna dengan kacamata, kondisi low-light, serta variasi pose wajah. Penambahan data ini bertujuan untuk meningkatkan kemampuan generalisasi model terhadap kondisi dunia nyata.

Ketiga, sistem dapat dikembangkan dengan mempertimbangkan analisis berbasis temporal yang lebih kuat, seperti penggunaan beberapa frame secara berurutan untuk menentukan kondisi kantuk. Pendekatan ini dapat mengurangi kemungkinan kesalahan deteksi akibat kedipan mata sesaat.

Keempat, perlu dilakukan integrasi penuh dengan sistem aplikasi utama, termasuk pengembangan fitur live camera dan optimalisasi performa pada sisi backend dan frontend. Hal ini akan memastikan bahwa sistem tidak hanya akurat, tetapi juga siap digunakan dalam implementasi nyata.

Terakhir, dashboard yang telah dikembangkan dapat terus ditingkatkan dengan menambahkan fitur monitoring performa model secara real-time, sehingga sistem dapat dievaluasi dan diperbaiki secara berkelanjutan.